

# Musica

Reconnaissance automatique d'accords par Intelligence Artificielle en utilisant le Deep Learning

Auteur: Tolotra RAHARISON

Matricule: 2584264

Email: [2584264@csfoy.ca](mailto:2584264@csfoy.ca)

CEGEP STE-FOY, QUEBEC – JUILLET 2026

# Contexte du projet

## PROBLÉMATIQUE

La transcription musicale automatique nécessite d'identifier avec précision les harmonies jouées. Le projet vise à automatiser cette tâche par l'apprentissage profond.

L'objectif est d'entraîner un modèle capable d'écouter un fichier audio contenant un accord isolé et de prédire sa classe harmonique avec une grande précision, en s'affranchissant des variations de timbre et de bruit.

## DÉFINITION DU MODÈLE

### Inputs (Entrées)

Un fichier audio (WAV) converti en une représentation temps-fréquence : le spectrogramme Chroma CQT

### Outputs (Sorties)

Une distribution de probabilités sur **36 classes** distinctes. (12 fondamentales chromatiques avec 3 qualités: Majeur, Mineur, Diminué).

# Objectifs techniques

Le problème traité est la **classification automatique d'accords musicaux**. À partir d'un fichier audio contenant un accord isolé, le système doit prédire la classe correspondante.

- Construire une chaîne d'apprentissage complète, de la donnée brute à la prédiction
- Générer un jeu de données annoté sans dépendre d'une annotation manuelle lourde
- Garder les essais reproductibles grâce à une configuration centralisée

Le prototype actuel reconnaît **36 classes** : accords majeurs, mineurs et diminués sur les **12 fondamentales chromatiques**.

# Pipeline général

La chaîne de traitement suit cette séquence, de la génération contrôlée des accords à la prédiction finale. L'ensemble est orchestré pour garantir la **reproductibilité**.




Les configurations du projet sont centralisées dans un fichier `musica.toml` (durée, fréquence, hyperparamètres) et alimente toutes les phases du pipeline.

# Génération des données

Pour pallier le manque de données annotées manuellement, le projet utilise une approche de **génération synthétique contrôlée**.

- Création de séquences **MIDI** précises pour les 36 classes d'accords ciblées.
- Synthèse audio en fichiers **WAV** via le synthétiseur logiciel **FluidSynth**.
- Utilisation d'une **SoundFont** standardisée pour garantir un timbre homogène lors de la génération de base.
- Mécanisme de secours intégré via **PrettyMIDI** en cas d'absence des dépendances FluidSynth.



# Augmentation et réalisme

Les accords propres générés par défaut sont trop éloignés des conditions réelles d'enregistrement. Plusieurs techniques d'augmentation sont appliquées :

- **Bruit de fond** : Ajout de bruit blanc, rose et d'environnements sonores.
- **Effets acoustiques** : Application de réverbération et de chorus.
- **Variété instrumentale** : Utilisation de multiples instruments et octaves.
- **Humanisation** : Légers décalages temporels et variations de vélocité.
- **Transposition** : Décalage de hauteur avec recalcul dynamique et automatique de l'étiquette (fondamentale).

## Pipeline d'augmentation

Accord propre (Synthétique)



+ Bruit & Effets



+ Humanisation & Transposition



Accord réaliste (Prêt pour l'entraînement)

# Organisation et répartition

---

## ■ Manifestes CSV

Indexation de chaque fichier audio avec son étiquette pour garantir la traçabilité des données.

## ■ Séparation stratifiée

Division garantissant la même proportion de classes (accords) dans chaque sous-ensemble.

## ■ Normalisation (Z-score)

Centrage et réduction appliqués uniquement sur le jeu d'entraînement pour éviter la fuite de données (data leakage).

## ■ Cache de features

Pré-calcul et sauvegarde des tenseurs Chroma CQT sur disque pour accélérer les itérations d'entraînement.

## Répartition du Dataset




|   |                      |       |
|---|----------------------|-------|
| ■ | Entraînement (70.6%) | 2 772 |
| ■ | Validation (14.7%)   | 576   |
| ■ | Test (14.7%)         | 576   |

# Architecture logicielle

L'architecture est organisée en **couches indépendantes** pour garantir une séparation stricte des responsabilités.

Cette conception modulaire facilite la maintenance, les tests isolés et la reproductibilité des expériences d'apprentissage.



# Expérimentation 1 : MLP Baseline

## ARCHITECTURE & HYPERPARAMÈTRES

| Paramètre             | Valeur / Choix                            |
|-----------------------|-------------------------------------------|
| Inputs                | Tenseur 2D aplati (Flatten) en vecteur 1D |
| Couches cachées       | 2 couches denses (Fully Connected)        |
| Neurones par couche   | 256 (Couche 1), 128 (Couche 2)            |
| Fonction d'activation | ReLU (Rectified Linear Unit)              |
| Initialisation        | Glorot Uniform                            |
| Optimiseur & LR       | Adam / Learning Rate = 0.001              |
| Fonction de perte     | Sparse Categorical Crossentropy           |
| Outputs               | Couche dense (36 neurones) + Softmax      |

## PERFORMANCES

ACCURACY (TEST)  
**~65.2%**

LOSS (TEST)  
**1.450**

## OBSERVATIONS

L'aplatissement des données détruit la structure spatio-temporelle du spectrogramme. Le modèle sature rapidement et peine à généraliser sur les variations de timbre.

# Expérimentation 2 : CNN Simple

## ARCHITECTURE

- **Couches cachées** : 2 couches convolutives (Conv2D, 32 filtres, kernel 3x3).
- **Réduction spatiale** : MaxPooling2D après chaque convolution.
- **Classification** : 1 couche dense (64 neurones) avant la sortie Softmax (36 classes).
- **Activation** : ReLU pour les couches cachées.

## HYPERPARAMÈTRES

- **Optimiseur** : Adam (Learning Rate = 0.001).
- **Fonction de perte** : Sparse Categorical Crossentropy.
- **Batch size** : 32.

## Performances (Validation)

|          |        |
|----------|--------|
| Accuracy | Loss   |
| ~ 85.0 % | ~ 0.45 |

## OBSERVATIONS

**Avantage** : Nette amélioration par rapport au MLP. Les filtres convolutifs capturent efficacement les relations spatio-temporelles locales du spectrogramme Chroma CQT.

**Problème** : Apparition rapide d'**overfitting** (surapprentissage) après 15 époques. Le modèle mémorise les données d'entraînement au détriment de la généralisation.

# Expérimentation 3 : CNN Optimisé

## ARCHITECTURE & HYPERPARAMÈTRES

- **Couches cachées** : 3 blocs convolutifs (32, 64, 64 filtres) + 1 couche dense (128 neurones).
- **Normalisation** : Batch Normalization après chaque convolution pour stabiliser l'apprentissage.
- **Régularisation** : Dropout agressif (25%) et pénalité L2 (0.001) sur les poids.
- **Optimiseur** : Adam (Learning Rate = 0.001).
- **Données** : Utilisation du dataset complet avec augmentation (bruit, pitch shift).

## Performances (Test Set)

Accuracy : 99.48%

Loss : 0.0380

## Observations

- La **Batch Normalization** accélère la convergence initiale.
- Le **Dropout** empêche le réseau de mémoriser le bruit d'entraînement.
- L'**augmentation des données** pour maintenir la performance sur des données inédites.

# Expérimentation 4 : Stratégies de régularisation

## RÉGULARISATION STRUCTURELLE

### Dropout

Désactivation aléatoire d'une fraction des neurones à chaque itération pour forcer le réseau à apprendre des caractéristiques redondantes.

**Paramètres** : 10% à 25% sur les couches convolutives, **50%** sur la couche dense finale.

### Régularisation L2

Ajout d'un terme à la fonction de perte proportionnel au carré des poids du modèle.

**Objectif** : Empêcher les poids de prendre des valeurs extrêmes, limitant ainsi la mémorisation du bruit d'entraînement.

## GARDE-FOUS DYNAMIQUES (CALLBACKS)

### Early Stopping

Interruption de l'entraînement si la performance sur le jeu de validation cesse de s'améliorer.

**Paramètres** : Surveillance de **val\_loss** avec une patience de 8 époques. Restauration des meilleurs poids.

### ReduceLROnPlateau

Réduction dynamique du taux d'apprentissage (Learning Rate) lorsque la perte stagne.

**Paramètres** : Facteur de réduction de **0.3** après une patience de 4 époques. Permet une convergence plus fine.

# Modèle final sélectionné

## ARCHITECTURE : CNN OPTIMISÉ

- **Couches cachées** : 3 blocs convolutifs (32, 64, 64 filtres) + 1 couche dense (128 neurones).
- **Activations** : ReLU (interne) et Softmax (sortie, 36 classes).
- **Régularisation** : Dropout (0.25) et Batch Normalization.
- **Optimiseur** : Adam (Learning Rate = 0.001).

Le CNN surpasse largement le MLP car il exploite la structure spatio-temporelle du spectrogramme CQT. Les filtres convolutifs capturent les relations harmoniques locales (intervalles), tandis que le Dropout prévient l'overfitting sur les données synthétiques.

## MÉTRIQUES D'ÉVALUATION

### MEAN SQUARED ERROR (MSE)

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

### CATEGORICAL CROSS-ENTROPY (LOSS)

$$L = - \sum_{i=1}^c y_i \log(\hat{y}_i)$$

### ACCURACY (PRÉCISION)

$$\text{Accuracy} = \frac{\text{Prédictions correctes}}{\text{Total des prédictions}}$$

# Mesures de performance

ACCURACY (TEST)


**99.48%**

F1 SCORE (MACRO)

**99.48%**

LOSS (TEST)

**0.038**



La matrice de confusion normalisée révèle une diagonale quasi-parfaite. Les rares erreurs (0.52%) se concentrent exclusivement sur des accords partageant une forte similarité harmonique (ex: C Majeur et A Mineur), démontrant la robustesse de l'extraction des caractéristiques CQT.

# Problèmes et solutions

## Défi rencontré

L'annotation manuelle d'un jeu de données audio est extrêmement chronophage et sujette aux erreurs.

Les accords générés par défaut manquent de réalisme acoustique et sont trop "propres".

La transposition audio modifie la fondamentale de l'accord, ce qui fausse l'étiquette initiale.

Les expériences de Machine Learning sont souvent difficiles à reproduire et à comparer.

## Solution apportée

**Génération contrôlée** permettant de créer des milliers d'exemples avec des étiquettes fiables dès la source.

**Augmentation audio** via l'ajout de bruit de fond, d'effets (réverbération) et d'humanisation.

**Recalcul dynamique** de la classe cible lors de l'application du décalage de hauteur (pitch shift).

**Traçabilité stricte** avec manifestes CSV, graines aléatoires et configuration centralisée.

# Avenues futures

## AMÉLIORATIONS DU MODÈLE

- **Données réelles** : Intégration d'enregistrements acoustiques (guitares, pianos) pour réduire la dépendance aux données synthétiques.
- **Vocabulaire étendu** : Ajout de nouvelles familles d'accords (septièmes, neuvièmes, suspendus, augmentés).
- **Contexte temporel** : Transition vers des architectures récurrentes (RNN/LSTM) ou des Transformers pour analyser des séquences d'accords complètes au lieu d'accords isolés.

## IMPLANTATION SYSTÈME

### Plugin VST / Audio Unit

Intégration du modèle directement dans les séquenceurs musicaux (DAW comme Ableton Live ou Logic Pro). Permet aux compositeurs d'obtenir une transcription en temps réel des pistes audio enregistrées.

### Application Web & API

Déploiement du modèle sur un serveur cloud. Les utilisateurs pourraient téléverser un fichier audio et recevoir instantanément une grille d'accords synchronisée avec le temps.